# Projeto 1 - Visualizing facts

Para este projeto foi-nos proposta a análise de dados e representação da resposta a uma pergunta colocada sobre os dados escolhidos. Foram-nos dadas várias bases de dados que poderíamos utilizar e a restrição de que deveria ser uma representação estática (sem interatividade) desenhada para a web. Escolhemos utilizar dados sobre carros, e após a análise dos mesmos, decidimos que iríamos perguntar qual o carro com a melhor relação peso-potência, com a resposta dada na forma de um bubble chart, de modo a também podermos representar a aceleração (característica impactada pelas referidas na pergunta).

O objetivo deste projeto era claro: responder a uma pergunta tendo em conta os dados ao nosso dispor, através de uma representação gráfica de fácil leitura. Determinámos rapidamente que não poderíamos colocar uma questão sem sabermos com que tipo de dados estávamos a trabalhar, pelo que escolher os dados em questão foi o primeiro passo. Quanto à segunda parte do objetivo, percebemos através das aulas que, de modo a ter uma boa representação, teríamos de ter em conta a relação dos dados entre si e as várias formas de representar essa relação. Pelo que a análise dos dados e a determinação da nossa pergunta foram passos essenciais para escolher o tipo de gráfico em uso.

O processo de análise dos dados foi bastante simples. Começámos por verificar que características existiam associadas a cada carro: MPG (milhas por galão); nº de cilindros; cilindrada; potência; peso; aceleração; modelo (que após análise, concluímos ser especificamente o ano do modelo) e origem. Seguidamente, pensámos em que perguntas podíamos colocar com estes dados. Descartámos perguntas baseadas na origem do carro (de onde são os carros mais pesados?), já que só existem três opções de origem e o número de carros de cada uma é bastante desigual (a grande maioria dos carros neste dataset são dos Estados Unidos). Assim, escolhemos uma pergunta que mostrasse a relação entre duas variáveis e que tivesse uma resposta “boa” e “má”: carros pesados e com pouca potência são “piores” que os leves e com muita potência. Decidimos também que seria interessante mostrar a origem e a aceleração destes carros, para ver se existiam padrões nas suas relações. Escolhida a pergunta, retirámos todas as características desnecessárias do dataset e verificámos se existiam dados por preencher, preenchendo os poucos em falta (apenas alguns com potência 0).

Tendo duas variáveis dependentes para relacionar, a solução óbvia seria utilizar um scatterplot para a nossa representação, mas tendo em conta as duas variáveis adicionais que tencionamos representar, surgiram 3 opções: bubble chart, parallel coordinates e sankey (sendo os últimos dois sugeridos por um docente). Decidimos optar pelo bubble chart devido à impossibilidade de utilizar interatividade e devido à sua clareza e simplicidade, proporcional à simplicidade da nossa pergunta.

Utilizámos 3 tipos de codificações visuais: posição, tamanho e cor. A posição está a codificar duas variáveis, o peso e a potência. A área de cada círculo representa o valor da aceleração e a cor utilizada, a origem.

Ana Inês França 2019213215
José Antunes 2019208836

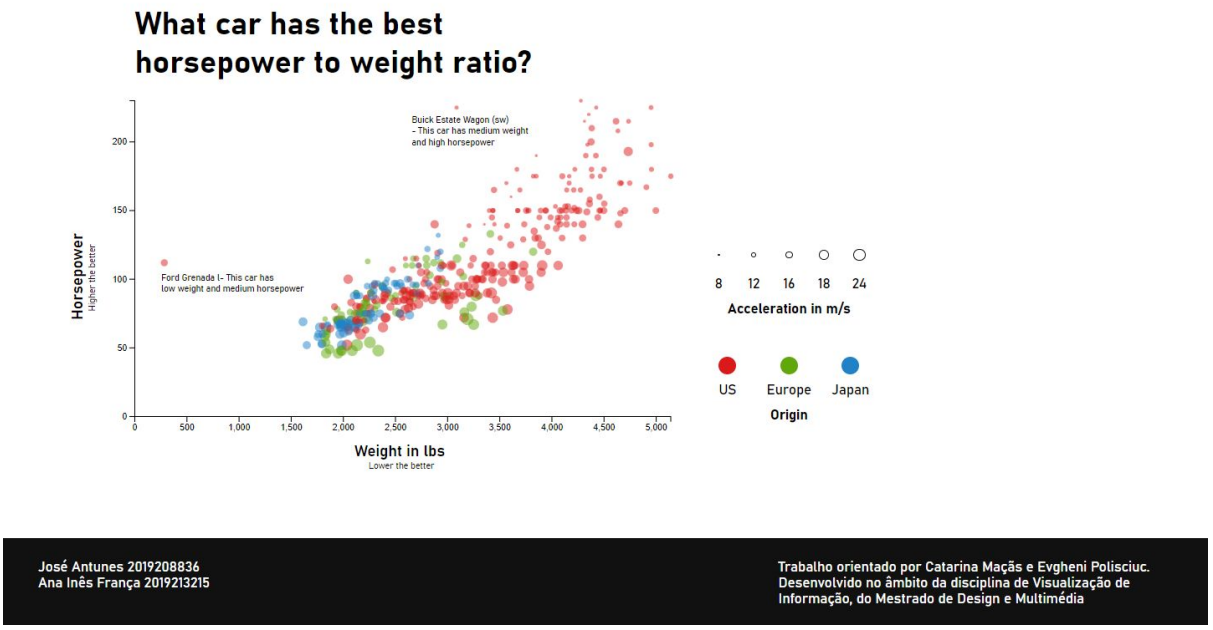



Fig. 1 - Captura de ecrã do website

Colocámos o peso nos eixo das abscissas devido a ser uma grandeza mais familiar que potência. Acrescentámos notas sobre a nossa perceção de qual seria o valor “bom” de cada uma das variáveis. Adotámos as escalas de cada eixo tendo em conta a facilidade de leitura e a relação entre elas (*Ticks* de 500 em 500 na abscissas e de 50 em 50 nas ordenadas).

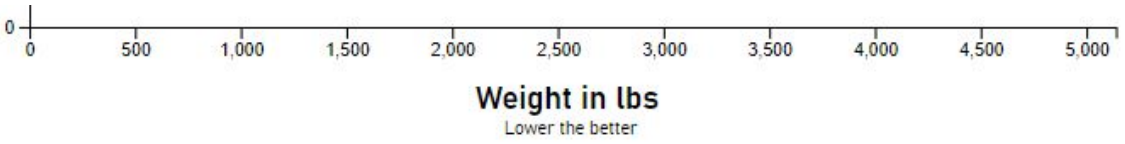



Fig.2 - Eixo das abscissas

A área de cada círculo representa o valor da aceleração. Inicialmente, tínhamos os valores exatos a serem utilizados para o desenho, mas não era possível verificar diferenças notáveis entre círculos. Então fizemos um mapeamento dos valores para uma escala diferente (de 8-24 passámos a 1.4-7 como medida do raio para o cálculo da área). Na legenda, colocámos os valores que cada círculo representa, de modo a dar a informação correta ao leitor.

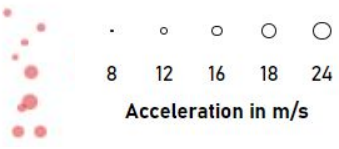



Fig. 3 - Círculos com diferentes áreas e legenda com os vários valores

Em termos de cor, fizemos uma associação baseada nas zonas que estavam a ser representadas, assim como uma associação às etiquetas que a linha de brinquedos "Hot Wheels" utiliza para distinguir categorias de carros. O que resultou na codificação que vemos utilizada. Há ainda que referir que, apesar de não estar a ser utilizada para qualquer codificação, adicionamos transparência aos pontos do gráfico de modo a facilitar a leitura, uma vez que existem várias sobreposições no gráfico.




Fig. 4 - Sobreposição de círculos com diferentes cores e respetiva legenda

Adicionalmente, notámos a existência de dois *outliers* que se destacavam, e considerando os conselhos dos docentes, optámos por os etiquetar.




Fig. 5 - Os dois *outliers* do nosso dataset e respetivas etiquetas

De modo geral, pensamos ter atingido o nosso objetivo. Elaborámos um gráfico simples mas que mostra com clareza os dados ao nosso dispor. Permite a perceção de padrões e tendências, assim como a resposta da pergunta colocada, independentemente daquilo que o leitor considere como “melhor”.

Ainda assim, há sempre espaço para melhoria, e refletindo sobre todo o processo, concluímos que deveríamos ter tido mais atenção ao dataset, uma vez que muitas das variáveis não tinham unidades de medida associadas. Isto fez com que tivéssemos que pesquisar e comparar valores de algumas variáveis em diferentes unidades de medida, para descobrir qual era a que estava a ser usada no nosso dataset.

Do mesmo modo, deveríamos ter feito mais testes com o dataset completo nas várias potenciais representações, na representação escolhida e com todos os visual encodings. Isto permitiria desenvolver mais alternativas para soluções a problemas que surgiram (por exemplo, a sobreposição de vários dados)

Outra coisa que gostaríamos de ter feito era desenvolver métodos para conectar a legenda ao gráfico mais eficazmente. Apesar de acharmos que neste momento os dois aparentam pertencer ao mesmo universo gráfico, perguntamo-nos se haveriam opções que os ligassem mais claramente.

Por fim, após uma conversa com os docentes, determinámos que a resposta à nossa pergunta dependia muito da perspetiva e objetivos do leitor. Assim, as anotações que acrescentámos aos eixos podem ser um bom ponto de partida para um leitor que não tenha um objetivo pré-definido ao interpretar o nosso gráfico, mas não serão úteis ou até mesmo corretas para todos os leitores.

Website : https://student.dei.uc.pt/~joseantunes/VI/Projeto_1/src/